Лабораторна робота № 3

Тема. Робота з великими мовними моделями через API. Основи Prompt Engineering

Виконав: Чубей Артем 311 група

Мета роботи: Ознайомитися з принципами взаємодії з великими мовними моделями (LLM), навчитися формулювати запити до мовних моделей та досліджувати вплив структури prompt на отриманий результат.

Використана модель: Google Gemini
Предметна область експериментів: Штучний інтелект та машинне навчання

Завдання 1. Взаємодія з великою мовною моделлю

1.1. Пояснення

- **Prompt:**

Поясни простими словами, що таке функція втрат (Loss Function) у машинному навчанні та навіщо вона потрібна.

- **Отримана відповідь:**

Функція втрат — це математичний інструмент, який вимірює, наскільки сильно модель помиляється. Уявіть учня, який готується до іспиту: чим більше помилок він робить у тестах, тим гірша його оцінка. Функція втрат перетворює розбіжність між передбаченням моделі та реальною правильною відповіддю на одне число. Завдання навчання нейромережі — налаштувати свої параметри так, щоб це число було якомога ближчим до нуля.

- **Аналіз результату:**

Модель використала вдалу побутову аналогію (учень та іспит), пояснила призначення терміна без надмірних математичних формул, відповівши чітко на запитання «навіщо вона потрібна».

1.2. Генерація тексту

- **Prompt:**

Напиши короткий вступний абзац (до 60 слів) для статті про актуальність згорткових нейронних мереж (CNN) у сучасному комп'ютерному зорі.

- **Отримана відповідь:**

Згорткові нейронні мережі залишаються фундаментальною основою комп'ютерного зору. Завдяки здатності ефективно виявляти просторові ієрархії ознак — від простих контурів до складних об'єктів — CNN забезпечують проривні результати в автономному транспорті, медичній діагностиці та системах безпеки, поєднуючи високу точність обробки із практичною обчислювальною стійкістю.

- **Аналіз результату:**

Текст академічний, лаконічний, містить конкретні сфери застосування (медицина, автопілоти) та вклався у заданий ліміт обсягу (44 слова).

1.3. Переклад

- **Prompt:**

Переклади українською мовою з дотриманням технічної термінології:

«Gradient descent is an iterative optimization algorithm used to minimize the loss function by updating parameters in the direction of steepest descent.»

- **Отримана відповідь:**

«Градієнтний спуск — це ітераційний алгоритм оптимізації, який використовується для мінімізації функції втрат шляхом оновлення параметрів у напрямку найшвидшого спуску.»

- **Аналіз результату:**

Переклад виконано без калькування, із коректним вживанням усталених термінів машинного навчання («ітераційний алгоритм оптимізації», «напрямок найшвидшого спуску»).

1.4. Узагальнення (Summary)

- **Prompt:**

Скороти та узагальни наступний текст до двох лаконічних тез:

«Перенавчання (overfitting) виникає, коли модель занадто детально підлаштовується під тренувальні дані, запам'ятовуючи навіть випадковий шум та несуттєві деталі. Через це на навчальній вибірці вона показує майже стовідсоткову точність, проте під час роботи з новими, реальними даними припускається грубих помилок. Основними методами боротьби з цим явищем є регуляризація, додавання шарів Dropout та збільшення обсягу навчального датасету.»

- **Отримана відповідь:**

    1. Перенавчання полягає у механічному запам'ятовуванні тренувальних даних разом із шумом, що погіршує здатність моделі узагальнювати на нових прикладах.
    2. Проблема вирішується застосуванням технік регуляризації (наприклад, Dropout) або розширенням навчальної вибірки.

- **Аналіз результату:**

Модель відкинула зайвий опис, чітко виділивши суть проблеми (теза 1) та способи її розв'язання (теза 2).

1.5. Генерація списку

- **Prompt:**

Сформуй список із 4 популярних оптимізаторів для навчання нейромереж. Для кожного вкажи його головну особливість у форматі: «Назва: особливість».

- **Отримана відповідь:**

    - **SGD (Stochastic Gradient Descent):** класичний підхід з обчисленням градієнта на випадкових міні-батчах, що забезпечує швидкість, але може коливатися біля локальних мінімумів.

- **Momentum:** накопичує імпульс руху попередніх кроків, допомагаючи прискорити спуск у потрібному напрямку та згладити коливання.
- **RMSprop:** адаптивно коригує швидкість навчання для кожного параметра окремо, ділячи градієнт на середньоквадратичне відхилення.
- **Adam:** поєднує переваги Momentum та RMSprop, забезпечуючи адаптивний крок та врахування інерції, завдяки чому є стандартом за замовчуванням.

- **Аналіз результату:**

Список згенеровано строго за зазначеним шаблоном («Назва: особливість»), інформація технічно точна та структурована.

Таблиця до Завдання 1

№	Тип завдання	Prompt	Результат (скорочено)	Аналіз
1	Пояснення	Поясни простими словами, що таке функція втрат...	Функція втрат вимірює помилку моделі (як оцінка на іспиті)...	Використано зрозумілу аналогію без перевантаження формулами.
2	Генерація тексту	Напиши короткий вступний абзац (до 60 слів) про CNN...	Згорткові нейромережі залишаються основою комп'ютерного зору...	Текст професійний, витримано ліміт за кількістю слів.

№	Тип завдання	Prompt	Результат (скорочено)	Аналіз
3	Переклад	Переклади українською: 'Gradient descent is an iterative...'	Градієнтний спуск — це ітераційний алгоритм оптимізації...	Термінологічно точний технічний переклад без кальки.
4	Узагальнення	Скороти та узагальни текст про overfitting до двох тез...	1. Модель запам'ятовує шум... 2. Вирішується регуляризацією...	Виділено лише ключову проблему та методи її вирішення.
5	Генерація списку	Сформуй список із 4 оптимізаторів (формат: Назва: особливість)...	SGD, Momentum, RMSprop, Adam із характеристиками ...	Чітко збережено заданий формат і критерії відбору.

Завдання 2. Порівняння способів формування prompt (Zero-shot vs Few-shot)

Задача: Класифікація гіперпараметрів нейромережі за категорією з обов'язковим визначенням типу даних у суворому форматі Параметр | Категорія | Тип даних.

Варіант 1: Zero-shot prompt (без прикладів)

- **Prompt:**

Класифікуй гіперпараметр learning_rate за категорією (Оптимізація / Архітектура / Регуляризація) та вкажи тип даних.

- **Результат моделі:**

Гіперпараметр learning_rate (швидкість навчання) належить до категорії **Оптимізація**.

Тип даних: число з рухомою комою (float), наприклад, 0.001 або 0.01. Він визначає розмір кроку під час оновлення ваг моделі.

- **Аналіз:** Модель відповіла правильно, проте згенерувала зайвий пояснювальний текст, не дотримавшись компактного табличного/рядкового формату.

Варіант 2: Few-shot prompt (із 3 прикладами)

- **Prompt:**

Класифікуй параметр за категорією (Оптимізація, Архітектура, Регуляризація) та типом даних за наведеним зразком:

Вхід: num_layers

Вихід: num_layers | Архітектура | int

Вхід: dropout_rate

Вихід: dropout_rate | Регуляризація | float

Вхід: batch_size

Вихід: batch_size | Оптимізація | int

Вхід: learning_rate

Вихід:

- **Результат моделі:**

learning_rate | Оптимізація | float

- **Порівняльний висновок:**
    - **Точність та відповідність завданню:** Few-shot забезпечив 100% відповідність заданому шаблону без вступних і заключних слів.
    - **Зміна структури:** У Zero-shot модель відповідала розлогими реченнями, у Few-shot — детермінованим рядком.
    - **Вплив прикладів:** Демонстрація 3 прикладів дозволила моделі зрозуміти синтаксис виводу без необхідності писати довгі текстові інструкції на зразок «не пиши нічого зайвого».

Завдання 3. Удосконалення prompt

1. Початковий (простий) prompt

- **Prompt:**

Розкажи про штучний інтелект.

- **Результат моделі:**

Штучний інтелект (ШІ) — це галузь комп'ютерних наук, що займається створенням систем, здатних виконувати завдання, які зазвичай вимагають людського інтелекту... *(далі 5 великих абзаців про історію, машинне навчання, робототехніку, етику, ChatGPT та майбутнє ШІ)*.

- **Аналіз недоліків:**
    - Запит занадто широкий і абстрактний.
    - Відсутня цільова аудиторія (не зрозуміло, це для дитини, школяра чи інженера).
    - Невизначений обсяг — модель згенерувала загальний оглядовий текст «про все і ні про що».

2. Вдосконалений prompt

- **Prompt:**

Роль: Викладач курсу «Вступ до штучного інтелекту» в технічному університеті.

Цільова аудиторія: Студенти 1 курсу спеціальності «Комп'ютерні науки».

Завдання: Поясни різницю між термінами «Штучний інтелект», «Машинне навчання» та «Глибоке навчання».

Формат: 3 пункти маркованого списку за принципом матрьошки (від ширшого до вужчого поняття), кожен пункт — рівно 2 речення.

Обсяг: До 100 слів.

- **Результат моделі:**
    - **Штучний інтелект (AI):** Це найширша наукова галузь, спрямована на створення комп'ютерних систем, здатних імітувати розумову діяльність людини. Вона охоплює як

експертні системи на базі правил, так і складні алгоритми навчання.

- **Машинне навчання (ML):** Це підгалузь ШІ, яка створює моделі, що самостійно знаходять закономірності в даних без прямого програмування кожного кроку. Алгоритм покращує якість своєї роботи з накопиченням досвіду та тренувальних прикладів.
- **Глибоке навчання (DL):** Це спеціалізований розділ машинного навчання, заснований на багатошарових штучних нейронних мережах. Такі мережі автоматично вилучають складні високорівневі ознаки з великих масивів зображень, тексту чи аудіо.

- **Висновок порівняння:**

Вдосконалений prompt усунув абстрактність, дав чітку структуру вкладеності понять і повністю вклався у форматний та обсяговий ліміт.

Таблиця до Завдань 2 і 3

Підхід	**Prompt**	**Результат**	**Висновок**
Zero-shot	Класифікуй гіперпараметр learning_rate за категорією (Оптимізація / Архітектура / Регуляризація) та вкажи тип даних.	Гіперпараметр learning_rate (швидкість навчання) належить до категорії Оптимізація. Тип даних: число з рухомою комою (float)...	Правильно за суттю, але містить зайвий розмовний текст, не дотримано лаконічного формату.
Few-shot	Класифікуй параметр за категорією та	learning_rate | Оптимізація | float	100% відповідність заданому

Підхід	Prompt	Результат	Висновок
	типом даних за зразком: num_layers | Архітектура | int; dropout_rate | Регуляризація | float; batch_size | Оптимізація | int. Вхід: learning_rate		шаблону виводу без супровідного тексту завдяки прикладам.
Початковий prompt	Розкажи про штучний інтелект.	Штучний інтелект (ШІ) — це галузь комп'ютерних наук... (5 великих абстрактних абзаців про історію, етику та майбутнє).	Запит надто розмитий, брак контексту, некерований обсяг та відсутність чіткої структури.
Вдосконалений prompt	Роль: Викладач. Аудиторія: Студенти 1 курсу. Завдання: Поясни різницю між AI, ML та DL. Формат: 3 пункти (матрьошка), по 2 речення. Обсяг: до 100 слів.	Штучний інтелект (AI): ... (2 речення) Машинне навчання (ML): ... (2 речення) Глибоке навчання (DL): ... (2 речення)	Повноцінне усунення «води», чітка логіка вкладеності понять, строгий контроль формату та обсягу.

Завдання 4. Використання системної ролі

Єдине тестове питання для всіх ролей: *«Що таке градієнтний спуск?»*

Роль 1: Викладач для початківців / школярів

- **System Prompt:** Ти шкільний вчитель фізики та інформатики, який пояснює складні речі дітям через прості метафори та життєві приклади.
- **Відповідь:**

Уявіть, що ви стоїте на вершині гори в густому тумані й вам потрібно спуститися на дно долини, але ви нічого не бачите. Що ви зробите? Ви спробуєте ногою землю навколо себе і зробите крок туди, де схил іде найкрутіше вниз. Градієнтний спуск — це саме такий метод: комп'ютер навпомацки робить невеликі кроки схилом, щоб знайти найнижчу точку, де помилок у його розрахунках найменше.

Роль 2: Senior Python/ML-програміст

- **System Prompt:** Ти Senior ML Engineer. Твій стиль — лаконічний, технічний, орієнтований на продакшн, формули, оптимізацію та код.
- **Відповідь:**

Градієнтний спуск — це first-order оптимізаційний алгоритм мінімізації диференційовної цільової функції $L(\theta)$. На кожній ітерації оновлюємо вектор ваг за формулою $\theta = \theta - \eta\nabla L(\theta)$, рухаючись протилежно до градієнта. У продакшні vanilla GD практично не використовується через $O(N)$ складність на епоху — замість нього беремо Mini-batch SGD або адаптивні оптимізатори на кшталт Adam із динамічним регулюванням learning rate η.

Роль 3: Академічний науковець / математик

- **System Prompt:** Ти професор математичного аналізу. Відповідай строго академічною мовою, використовуючи точні математичні терміни та векторний аналіз.
- **Відповідь:**

Градієнтний спуск є чисельним методом розв'язання задач безумовної нелінійної оптимізації. Нехай задана диференційовна функція багатьох

змінних f: R^n -> R. Вектор градієнта $\nabla f(x)$ визначає напрямок найшвидшого зростання функції, отже, вектор антиградієнта $-\nabla f(x)$ визначає локальний напрямок найшвидшого спадання. Метод полягає у побудові послідовності наближень $x_{k+1} = x_k - \alpha_k \nabla f(x_k)$, яка за умов опуклості та ліпшицевості градієнта збігається до локального екстремуму.

- **Висновок про вплив ролі:**

Системна інструкція кардинально змінює лексику, рівень абстракції та фокус уваги моделі навіть при абсолютно однаковому питанні:

  - *Вчитель* фокусується на інтуїції та аналогіях.
  - *Інженер* фокусується на практичній реалізації, обчислювальній складності та коді.
  - *Науковець* фокусується на формальних математичних визначеннях та умовах збіжності.

5. Відповіді на контрольні запитання

1. **Що таке LLM?**
   Велика мовна модель (Large Language Model) — нейромережева модель глибокого навчання (зазвичай архітектури Transformer), навчена на гігантських масивах текстових даних для генерації, розуміння та обробки природної мови.

2. **Що таке prompt?**
   Текстовий вхідний запит, контекст або інструкція, яку користувач передає мовній моделі для отримання певної відповіді чи виконання задачі.

3. **Що таке Prompt Engineering?**
   Дисципліна та методологія розробки, оптимізації та структурування промптів для отримання найбільш точних, якісних, детермінованих і релевантних відповідей від LLM.

4. **Що таке zero-shot prompting?**
   Підхід, за якого моделі ставиться завдання без надання будь-яких прикладів виконання (модель спирається виключно на свої базові знання, отримані під час попереднього навчання).

5. **Що таке few-shot prompting?**
   Підхід, за якого в тіло промпту перед основним завданням додається невелика кількість прикладів (зазвичай від 2 до 5) у форматі «вхідні дані -> бажаний результат».

6. **У чому відмінність між zero-shot та few-shot prompting?**
   Zero-shot не містить зразків і підходить для простих завдань, проте не гарантує суворий формат виводу. Few-shot містить демонстраційні приклади, що дає змогу точно навчити модель бажаному формату виводу, синтаксису та специфічній логіці міркувань.

7. **Для чого використовується system role?**
   Системна роль задає глобальний контекст, персону, тон спілкування, правила поведінки та обмеження для моделі на весь сеанс взаємодії, керуючи стилем та глибиною відповідей.

8. **Які елементи може містити ефективний prompt?**
   Роль (персону), передісторію/контекст задачі, чітку інструкцію (дієслово дії), вхідні дані, обмеження (чого робити не можна),

очікуваний формат виводу (JSON, таблиця, маркований список) та бажаний обсяг.

9. **Чому одна й та сама LLM може давати різні відповіді на різні prompt?**
   LLM працює на основі ймовірнісного розподілу наступних токенів. Будь-яка зміна структури або навіть одного слова в промпті змінює контекстний вектор механізму уваги (self-attention), спрямовуючи генерацію іншою ймовірнісною траєкторією.
10. **Які основні причини неякісної відповіді мовної моделі?**
    Неоднозначність або надмірна абстрактність запиту, брак контексту, взаємовиключні інструкції, галюцинації через відсутність достовірних даних у навчальній вибірці та перевищення ліміту контекстного вікна моделі.

6. Загальні висновки

1. Досліджено практичні аспекти використання великих мовних моделей на прикладі Google Gemini, яка продемонструвала високу якість генерації, узагальнення, форматування та технічного перекладу в галузі штучного інтелекту.
2. Експериментально доведено перевагу Few-shot над Zero-shot у завданнях зі суворими вимогами до структуризації даних: наявність зразків повністю усуває небажаний супровідний текст моделі.
3. Встановлено, що деталізація промпту (додавання ролі, аудиторії, формату, обмежень) перетворює абстрактну енциклопедичну відповідь на прикладний інженерний результат.
4. Продемонстровано ключову роль системної інструкції (System Role) у формуванні цільового тону викладу (від дитячих метафор до суворих математичних доведень).
5. Опанування методів Prompt Engineering є обов'язковою практичною навичкою для ефективного використання штучного інтелекту в професійній діяльності.